Cahier des charges — SIVCAF

Oct 29, 2026 · @john wick

1. Contexte et objectifs

SIVCAF (Système Intelligent de Vérification et de Classement Automatique des Factures) automatise le tri des factures photographiées ou numérisées. Aujourd'hui, ce tri se fait à la main : il faut identifier le type de document, relire les montants et l'orienter vers le bon service.

Objectifs du système :

1. **Classer** chaque document selon son type avec un réseau de neurones convolutif (CNN).
2. **Détecter** les documents inexploitables : flous, mal cadrés ou mal exposés.
3. **Extraire** par OCR les informations utiles : numéro, date, émetteur, identifiants fiscaux, IBAN, montants HT, TVA, TTC et net à payer.
4. **Vérifier** la cohérence des données : HT + TVA = TTC, taux de TVA valide, champs obligatoires, doublons.
5. **Orienter** chaque document vers la file de traitement appropriée.
6. **Conserver** les résultats dans une base consultable et corrigeable depuis une interface web.

Indicateur clé : sur le jeu de validation synthétique, le modèle actuel classe correctement **98,75 %** des types et **100 %** des états de qualité.

2. Périmètre

Le système traite des factures isolées, image ou PDF, de six types et de plusieurs pays francophones.

Inclus

- Formats d'entrée : PNG, JPG/JPEG, BMP, TIF/TIFF, WEBP, PDF.
- Six types de documents : énergie (électricité/gaz), eau, télécom, fournisseur, ticket de caisse, document non reconnu.
- Pays pris en charge : France, Maroc, Algérie, Tunisie, RD Congo, Sénégal, Côte d'Ivoire, Cameroun, Belgique, Suisse, Canada.
- Interface web, API JSON, ligne de commande et export CSV.

- Génération d'un jeu d'entraînement synthétique et réentraînement sur les factures validées.

Exclu

- Comptabilisation dans un logiciel comptable ou ERP (l'export CSV sert d'interface).
- Paiement des factures.
- Gestion multi-utilisateurs, authentification et droits d'accès.
- Extraction ligne par ligne du détail des articles.

3. Acteurs et utilisateurs

Acteur	Rôle	Interface utilisée
Opérateur de saisie	Dépose les factures, consulte le résultat	Tableau de bord web
Contrôleur comptable	Traite les documents à vérifier, corrige les champs OCR, valide ou rejette	Fiche document
Comptabilité (charges, fournisseurs, notes de frais)	Reçoit les factures validées, les marque traitées	Liste filtrée, export CSV
Administrateur technique	Installe, entraîne et réentraîne le modèle, ajuste les seuils	Ligne de commande, config.py
Système tiers	Envoie des documents et lit les résultats	API JSON

4. Exigences fonctionnelles

4.1 Acquisition des documents

- **EF-01** Importer un ou plusieurs fichiers par glisser-déposer, par l'API (`POST /api/analyser`) ou en ligne de commande (fichier ou dossier).
- **EF-02** Convertir la première page d'un PDF en image.
- **EF-03** Copier le fichier original dans `data/uploads/` et calculer son empreinte SHA-256.

4.2 Contrôle de qualité de l'image

- **EF-04** Classer la qualité par CNN en 4 états : conforme, flou, mal cadré, exposition incorrecte.
- **EF-05** Mesurer par OpenCV : netteté (variance du laplacien ⩾ 180), luminosité (⩾ 110), contraste (⩾ 12), inclinaison (⩽ 12°), surface du document (⩾ 12 % de l'image), bords coupés.
- **EF-06** Détecter le contour de la feuille et redresser la perspective avant l'OCR.
- **EF-07** Rejeter le document si le CNN donne ⩾ 60 % « non conforme », ou si 2 alertes OpenCV sont levées, ou si le CNN donne ⩾ 40 % avec 1 alerte.

4.3 Classement par type

- **EF-08** Classer le document parmi 6 types par CNN à partir de la mise en page globale.
- **EF-09** Combiner l'avis du CNN avec un classement par le texte OCR : vocabulaire métier (kWh, m3, forfait, qté…) et fournisseurs connus (REGIDESO, Sonelgaz, Lydec, ONEE, STEG, SENELEC, Djezzy…).
- **EF-10** Ne pas classer en « non reconnu » un document dont le texte montre clairement une facture.

4.4 Extraction OCR

- **EF-11** Reconnaître le texte avec Tesseract (langue `fra`) s'il est installé, sinon EasyOCR ; moteur forçable par la variable `SIVCAF_OCR`.
- **EF-12** Extraire : numéro, date, émetteur, SIRET ou identifiant fiscal national, TVA intracommunautaire, IBAN, montant HT, taux et montant de TVA, TTC, net à payer.
- **EF-13** Lire tous les formats de montants : `1 234,56`, `1.234,56`, `1'234.50`, `25,210 DT`, `15 000 FCFA`.
- **EF-14** Détecter le pays et la devise à partir des indices du texte (devise, identifiants, indicatif téléphonique, villes, fournisseurs).
- **EF-15** Distinguer le montant de la facture du net à payer (arriérés, timbre).

4.5 Contrôles métier

- **EF-16** Signaler une anomalie si le montant, la date ou le numéro (sauf ticket de caisse) est introuvable.
- **EF-17** Signaler une date dans le futur ou de plus de 10 ans.
- **EF-18** Vérifier HT + TVA = TTC, avec une tolérance de max(0,05 ; 0,05 % du TTC).
- **EF-19** Vérifier que la TVA correspond au taux annoncé et que ce taux est valide dans le pays détecté.

- **EF-20** Exiger un identifiant fiscal sur les factures fournisseurs.
- **EF-21** Détecter les doublons : même empreinte de fichier, ou même numéro + émetteur + montant.

4.6 Orientation

- **EF-22** Attribuer une décision et une file de traitement selon les règles ci-dessous, avec la liste des motifs.

Décision	Condition	File de traitement
REJETEE	Qualité insuffisante (EF-07)	Re-numérisation demandée
DOUBLON	Doublon détecté (EF-21)	Contrôle des doublons
NON_FACTURE	Classé « autre » avec confiance suffisante	Tri manuel
A_VERIFIER	Confiance de classement < 70 % ou anomalie OCR	Vérification manuelle
VALIDEE	Tout est conforme	Énergie, eau, télécom → Charges et abonnements ; fournisseur → Comptabilité fournisseurs ; ticket → Notes de frais

4.7 Interface web

- **EF-23** Tableau de bord : compteurs par décision, montant validé, liste filtrable par décision, type ou texte.
- **EF-24** Fiche document : aperçu, probabilités du CNN, mesures de qualité, motifs, champs OCR modifiables, texte reconnu.
- **EF-25** Actions sur un document : valider, rejeter, marquer traité, réanalyser, supprimer.
- **EF-26** Export CSV (séparateur `;`, compatible Excel).

4.8 API JSON

Méthode	Route	Fonction
POST	`/api/analyser`	Analyse un ou plusieurs fichiers (champ multipart `fichiers`)
GET	`/api/factures`	Liste, filtres `decision`, `type_doc`, `recherche`

Méthode	Route	Fonction
GET	`/api/factures/<id>`	Détail complet d'un document
GET	`/api/statistiques`	Agrégats

4.9 Apprentissage

- **EF-27** Générer un jeu synthétique (≈ 2 400 images) simulant scans et photos avec défauts étiquetés.
- **EF-28** Entraîner sur un dossier réel accompagné d'un fichier `etiquettes.csv` (`fichier,type,qualite`).
- **EF-29** Réentraîner avec les factures validées ou corrigées, chacune déclinée en 12 variantes simulées, puis réanalyser la base.
- **EF-30** Calibrer les taux d'alerte des contrôles OpenCV par classe de qualité.

5. Exigences non fonctionnelles

Domaine	Exigence
Exécution	Fonctionne sur CPU, sans GPU (PyTorch version CPU). Entraînement initial en quelques minutes.
Autonomie	Aucune dépendance obligatoire hors Python : EasyOCR fonctionne sans installation système (modèles d'environ 100 Mo téléchargés au premier usage).
Traçabilité	Chaque décision conserve ses motifs, les probabilités du CNN, les mesures de qualité, le moteur OCR et la durée de traitement (ms).
Paramétrage	Les seuils de décision sont centralisés dans `config.py` et `qualite.py`.
Extensibilité	Un pays s'ajoute dans `PAYS` (`pays.py`), un fournisseur dans `INDICES` (`classement_texte.py`), avec un cas de test associé.
Portabilité	Windows, Linux et macOS.
Ergonomie	Interface web en français, montants formatés selon la devise, champs corrigeables sur la fiche.

Domaine	Exigence
Qualité du code	Tests unitaires d'extraction (`tests/test_extraction.py`).

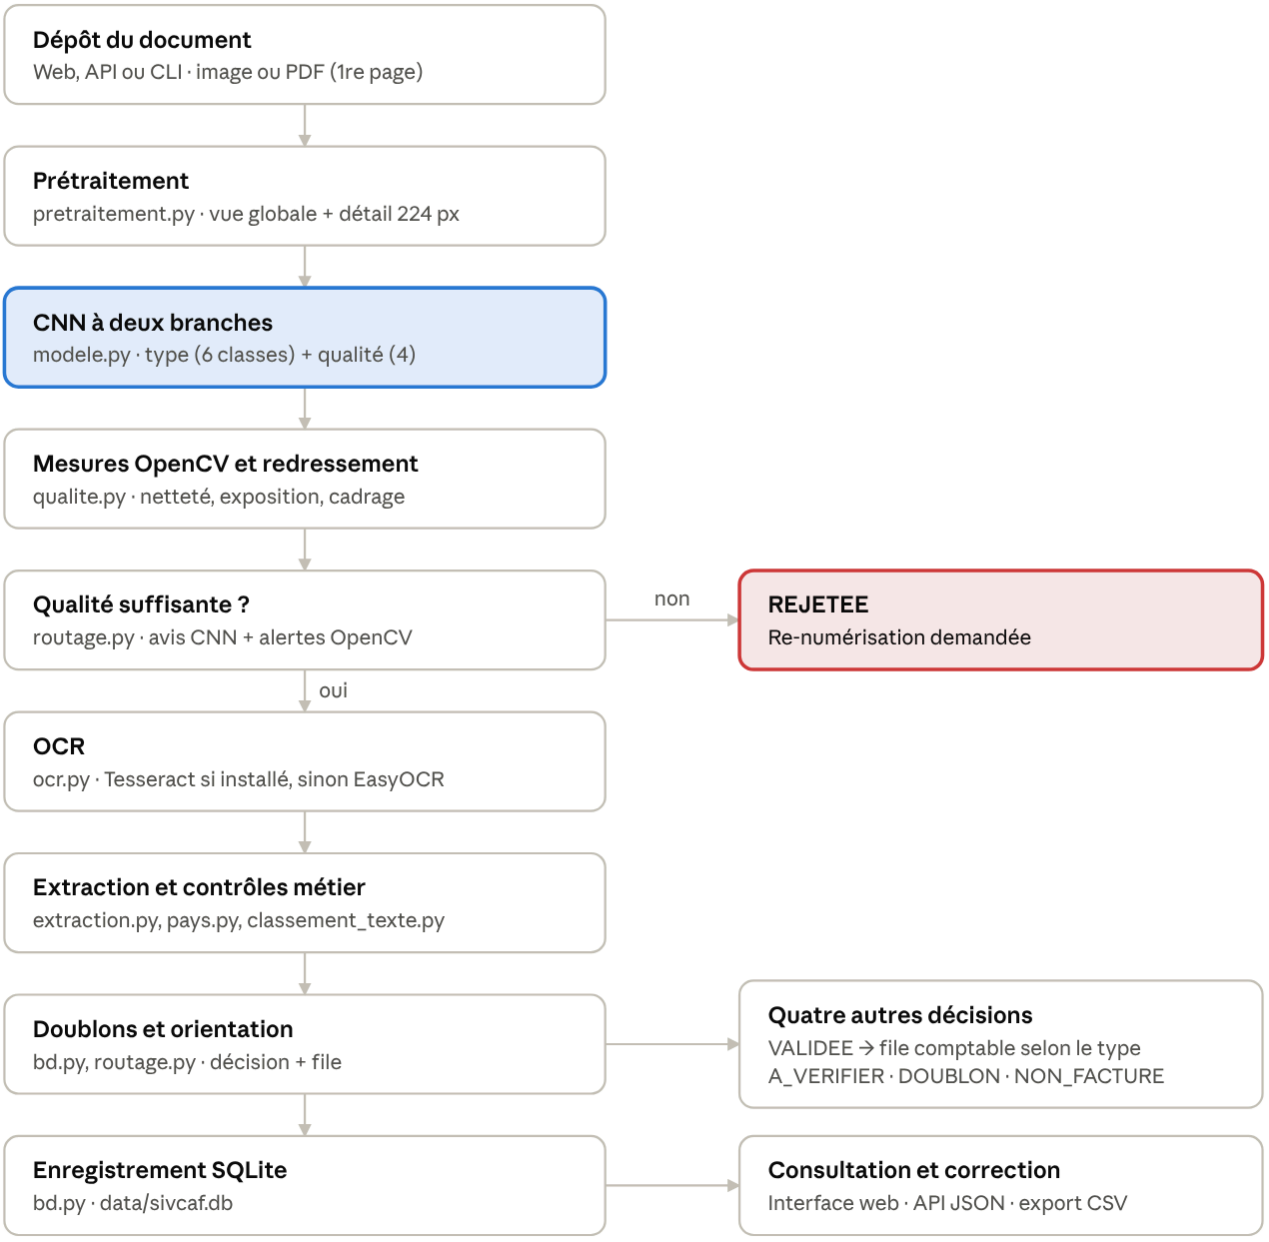
Points à trancher :

- [ ] Temps de traitement maximal par document attendu en production.
- [ ] Authentification et chiffrement si l'application est exposée hors du poste local (le serveur écoute aujourd'hui sur 127.0.0.1:5000).
- [ ] Durée de conservation des fichiers et des données personnelles (IBAN, identifiants).

6. Architecture et choix techniques

L'application est un paquet Python (`sivcaf/`, environ 2 300 lignes) qui exécute une chaîne de traitement séquentielle pour chaque document.

Un document passe la qualité avant l'OCR, puis reçoit une décision



chaîne de traitement · 9 étapes, 1 rejet

Un document de mauvaise qualité sort de la chaîne avant l'OCR ; les autres reçoivent une décision puis sont enregistrés.

Pourquoi un CNN à deux branches ? Une page réduite à 224 px ne permet plus de juger la netteté des caractères. La branche « détail » observe la zone la plus texturée à résolution quasi native. La tête qualité combine les deux branches ; la tête type n'utilise que la vue globale.

Composant	Technologie
Langage	Python 3.12
Apprentissage profond	PyTorch, torchvision (CPU)
Traitement d'image	OpenCV, NumPy, Pillow
OCR	Tesseract (pytesseract) ou EasyOCR
Lecture PDF	pypdfium2
Application web et API	Flask
Base de données	SQLite

7. Modèle de données

Une table unique `factures` (SQLite, `data/sivcaf.db`) stocke un document par ligne. Les colonnes `pays`, `devise` et `net_a_payer` sont ajoutées automatiquement à l'ouverture d'une base ancienne.

Groupe	Colonnes
Fichier	`id`, `date_import`, `fichier_original`, `chemin_stocke`, `empreinte` (SHA-256)
Classement CNN	`type_doc`, `confiance_type`, `qualite`, `confiance_qualite`, `probas` (JSON)
Qualité OpenCV	`mesures_qualite` (JSON)
Données extraites	`numero`, `date_facture`, `emetteur`, `siret`, `tva_intracom`, `iban`, `montant_ht`, `taux_tva`, `montant_tva`, `montant_ttc`, `net_a_payer`, `pays`, `devise`
OCR	`texte_ocr`, `moteur_ocr`, `anomalies` (JSON)
Orientation	`decision`, `file_traitement`, `motifs` (JSON)
Suivi	`statut` (`en_attente`, `traitee`, `corrigee`), `duree_ms`

Index : `empreinte` ; (`numero`, `emetteur`) pour les doublons ; `decision` pour les filtres.

8. Contraintes, livrables et critères d'acceptation

Contraintes

- Aucun corpus de factures réelles n'est fourni : l'entraînement initial repose sur des données synthétiques.
- Les mises en page varient selon le pays et le fournisseur : le CNN seul ne peut pas toutes les connaître, d'où le classement complémentaire par le texte.
- Seule la première page des PDF est analysée.

Livrables

Livrable	Emplacement
Code source du paquet Python	`sivcaf/`
Modèle entraîné et ses métriques	`models/cnn_factures.pt`, `models/cnn_factures.json`
Jeu d'entraînement synthétique	`data/dataset/`
Application web et API	`sivcaf/web.py`, `sivcaf/templates/`
Tests	`tests/test_extraction.py`
Documentation d'installation et d'utilisation	`README.md`

Critères d'acceptation

- [ ] Précision de classement du type ⩾ 95 % sur le jeu de validation (mesurée : 98,75 %).
- [ ] Précision de classement de la qualité ⩾ 95 % (mesurée : 100 %).
- [ ] Tous les tests d'extraction passent.
- [ ] Un document flou ou coupé est rejeté avec un motif explicite.
- [ ] Une facture déposée deux fois est marquée DOUBLON.
- [ ] Une incohérence HT + TVA ≠ TTC envoie le document en A_VERIFIER.
- [ ] Une facture de chaque pays pris en charge est reconnue avec la bonne devise.
- [ ] L'export CSV s'ouvre correctement dans Excel.

Les seuils de 95 % sont proposés ; à confirmer, ainsi qu'un objectif mesuré sur des factures réelles.